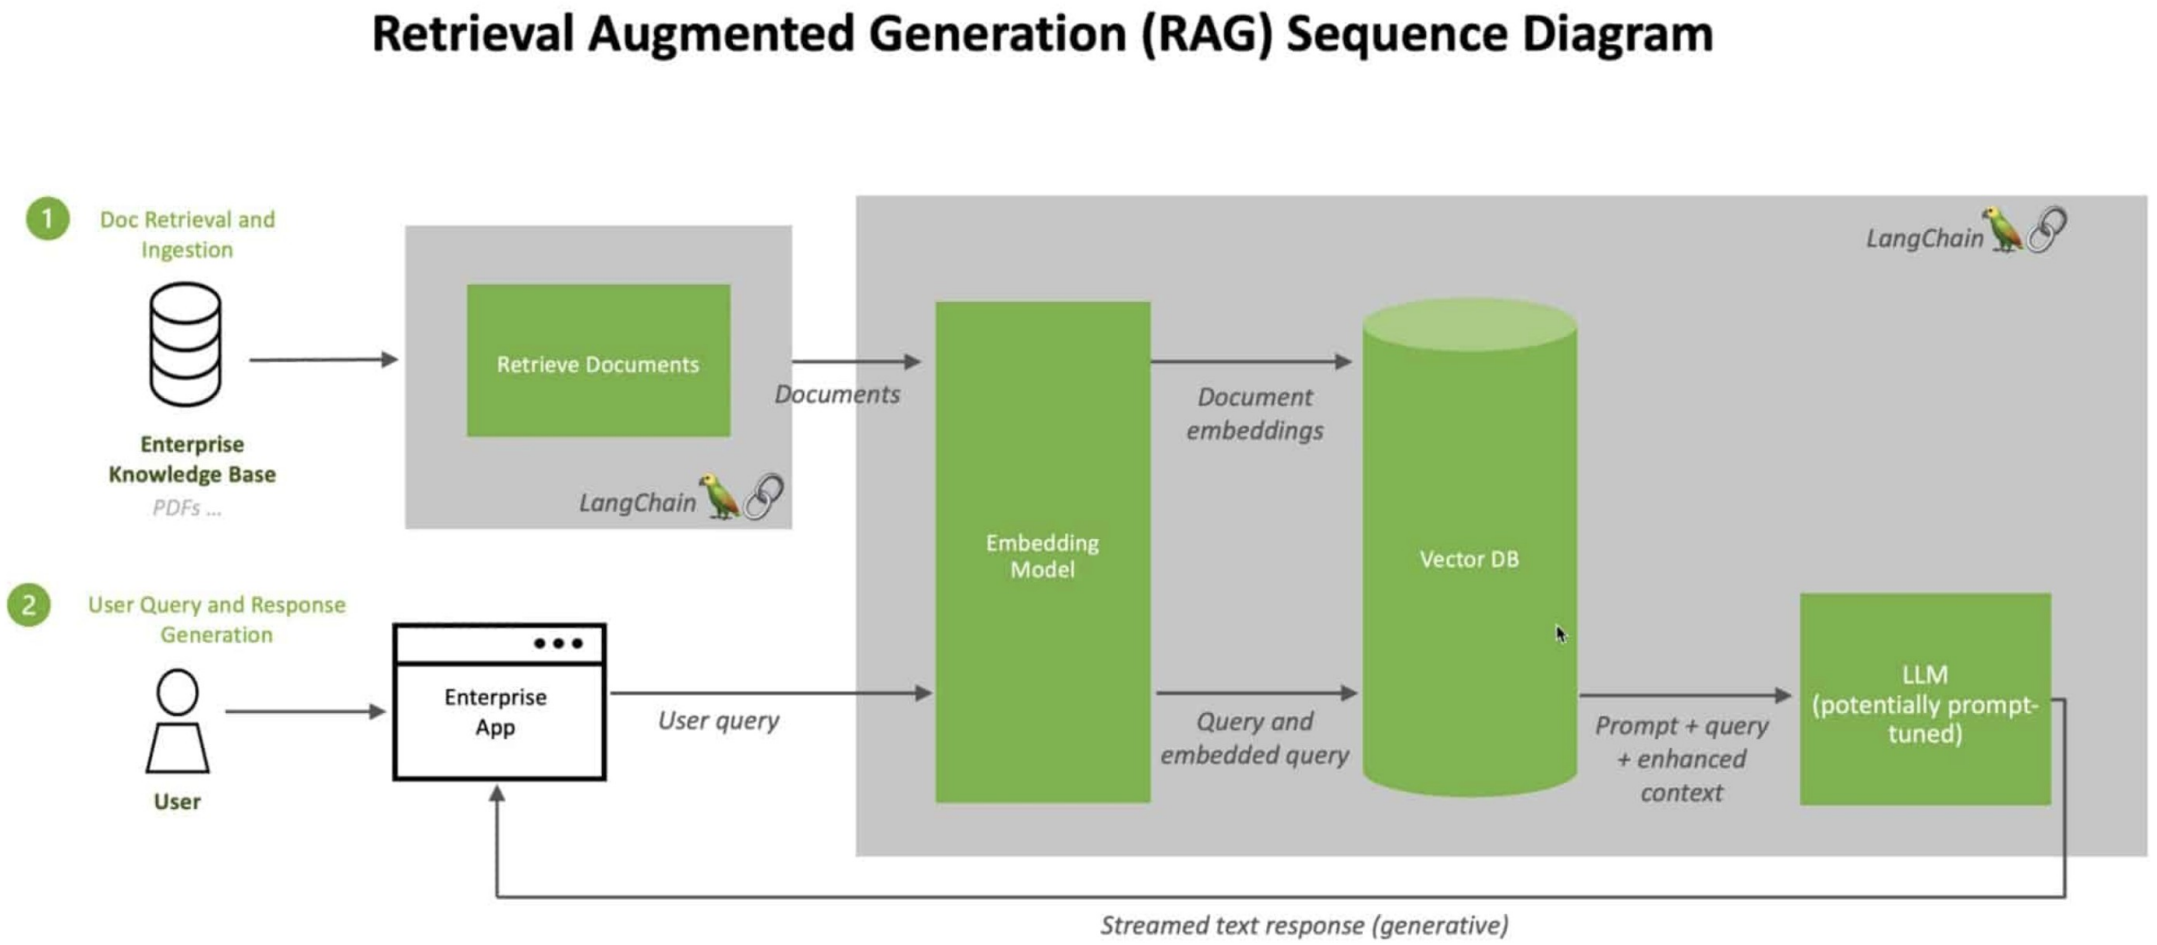
RAG: поиск и генерация



Внешние документы **Контекст для LLM**

Chunking: единица поиска

«Возврат товара возможен в течение 14 дней.
Для цифровых товаров действуют отдельные условия.»

Фрагмент	Содержание
Чанк A	Возврат товара возможен в течение 14 дней.
Чанк B	14 дней. Для цифровых товаров действуют отдельные условия.

Границы смысла **Overlap** **Источник + раздел**

BM25: совпадения слов

$$\mathrm{BM25}(q,d) = \sum_{t \in q} \mathrm{IDF}(t)\, \frac{f(t,d)(k_1+1)}{f(t,d) + k_1\left(1 - b + b\frac{|d|}{\mathrm{avgdl}}\right)}$$



Редкость слова

Насыщение частоты

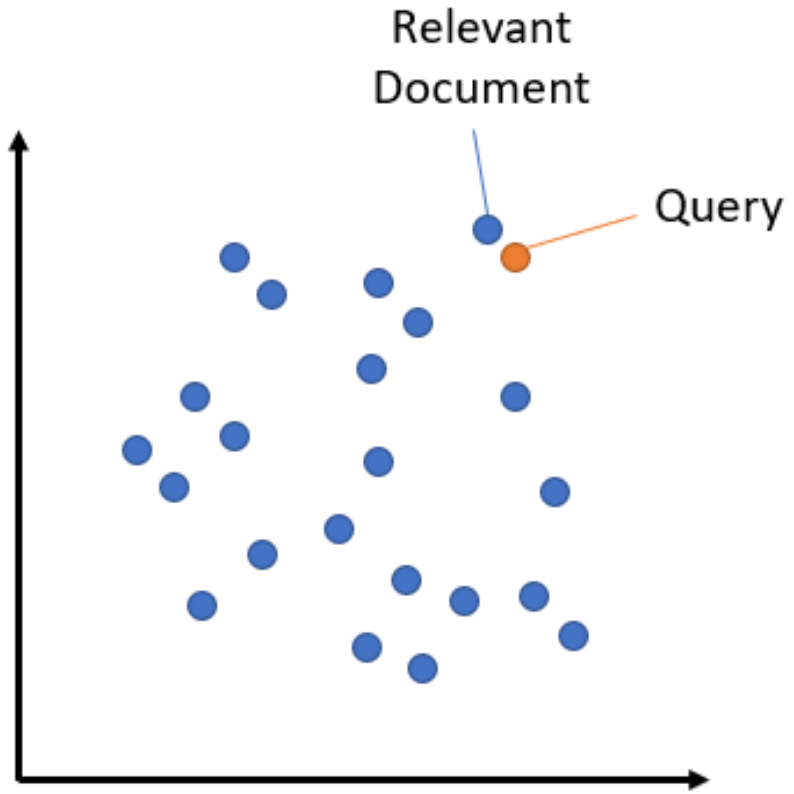
Поправка на длину

BM25 и dense: разные сигналы

Запрос	Полезный сигнал
«Ошибка E1042»	Точный идентификатор BM25
«Как вернуть покупку?»	«Порядок возврата товара» Dense
«Возврат модели XZ-17»	Идентификатор + смысл Hybrid

Токенизация и язык корпуса влияют на выдачу

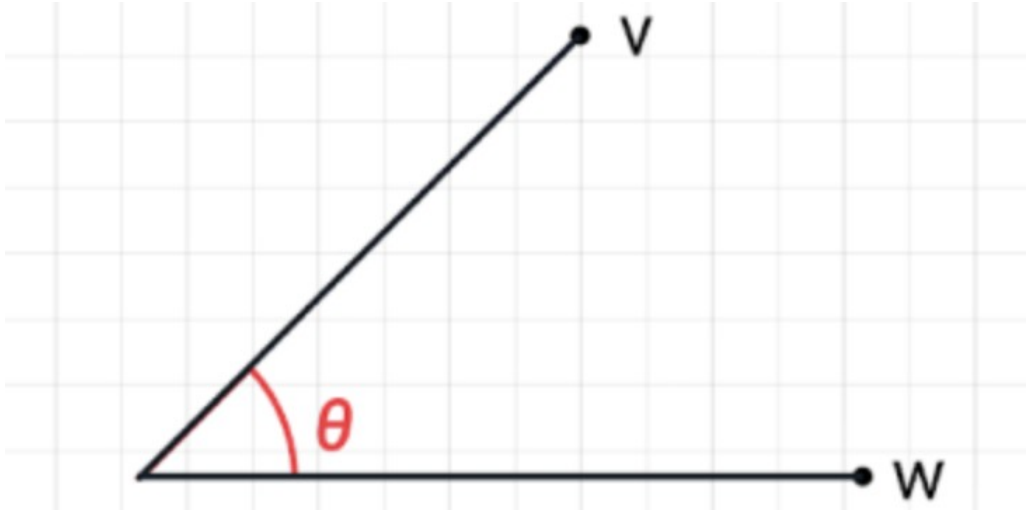
Dense retrieval: bi-encoder



Документы: заранее

Запрос: при обращении

Cosine, inner product и L2

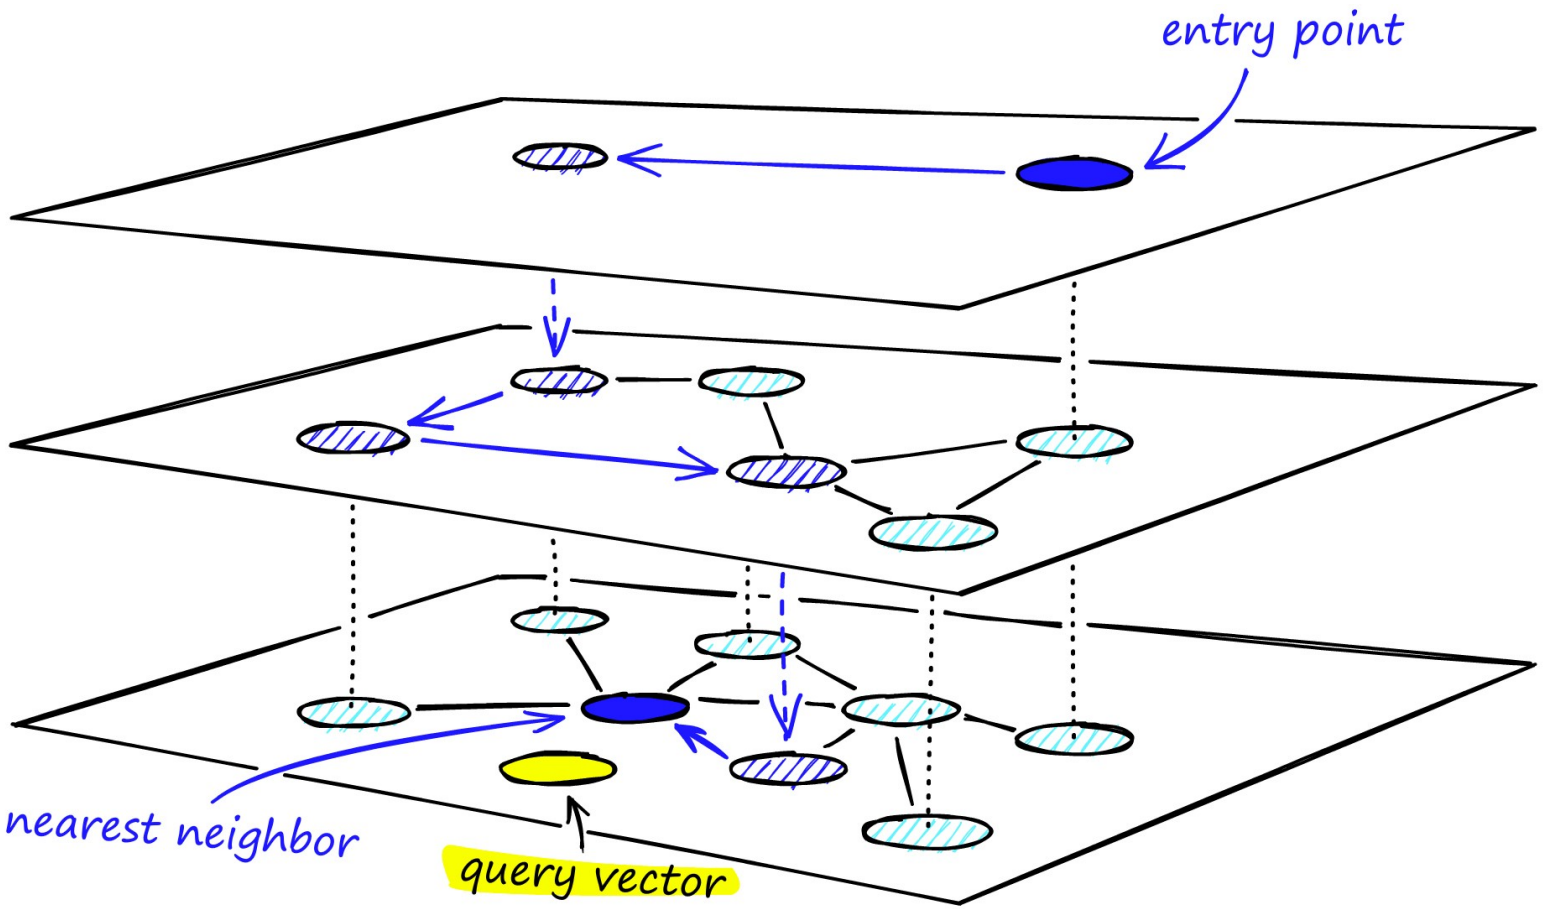


$$cos(v, w) = \frac{v.w}{||v|| \times ||w||}$$

$$\|u\| = \|v\| = 1 \quad \Rightarrow \quad \|u - v\|^2 = 2 - 2u^\top v$$

Нормированные векторы: одинаковый порядок соседей

ANN: поиск по части векторов



Полный перебор

O(Nd)

HNSW

Иерархия графов

efSearch:
скорость / recall

Ближайший вектор ≠ релевантный ответ

Hybrid: объединение выдач

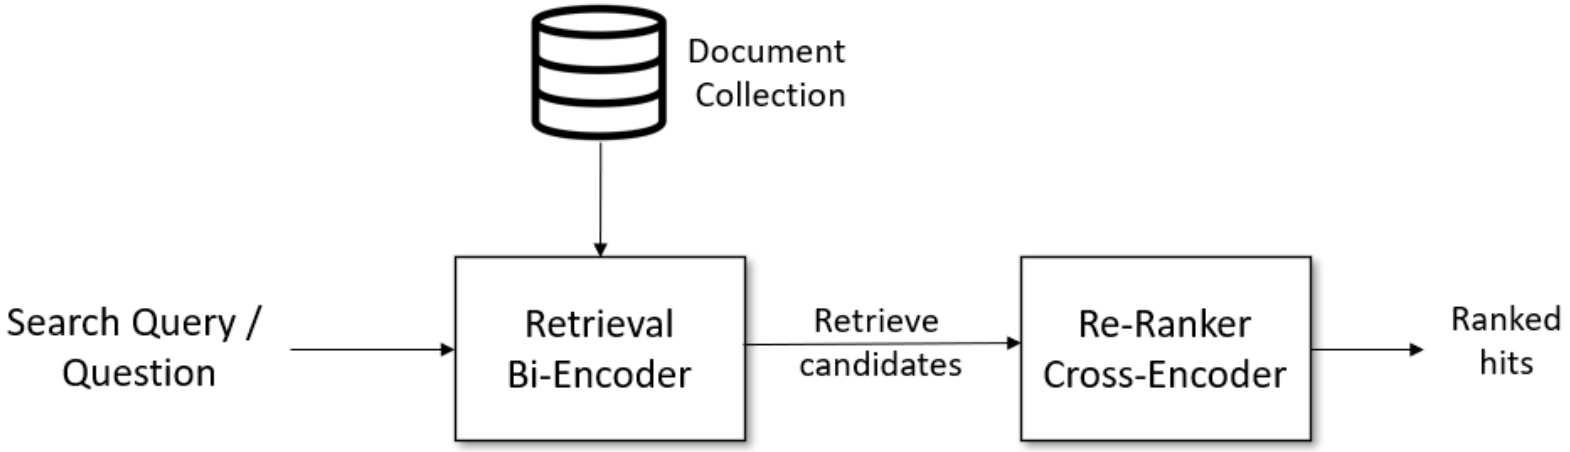
$$\mathrm{RRF}(d) = \sum_{r \in \{\mathrm{BM25},\, \mathrm{dense}\}} \frac{1}{c + \mathrm{rank}_r(d)}$$

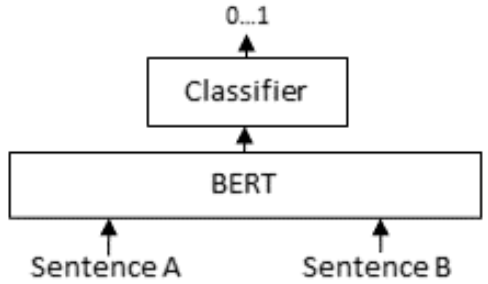
Документ	Ранг BM25	Ранг dense	RRF, c = 60
A	1	3	0.03227
B	2	1	0.03252
C	3	2	0.03200

Итог: B, A, C

Ранги вместо несопоставимых скоров

Reranking: оценка пары





50 кандидатов

5 фрагментов в контекст

Индекс и векторная база

Уровень	Задача	Примеры
Модель / score	Релевантность	BM25, bi-encoder
Индекс	Поиск кандидатов	Инвертированный, HNSW
Библиотека	Операции с индексами	FAISS
База	Хранение, метаданные, фильтры	Chroma, Qdrant, Milvus

Выбор индекса отдельно от выбора базы

Оценка: где возникла ошибка?

Этап	Что проверяем
ANN	Совпадение с точным top-k
Retrieval	Recall@k, precision@k
Генерация	Правильность, groundedness
Ссылки	Поддержка конкретных утверждений

Правильный контекст ≠ правильный ответ

Практика: одна база, разные вопросы

Точный код	«Ошибка E1042»
Перефразировка	«Как вернуть покупку?»
Нет ответа в базе	«Когда выйдет XZ-18?»

Top-k → контекст → ответ → источник