СЕМИНАР · 80 МИН

RAG · Part 2
От документов к ответу

Загрузка · чанки · эмбеддинги · retriever

Дастан Омирзак
МФТИ · осень 2026

girafe ai

План занятия

1. Документы и чанки

2. Эмбеддинги и кэш

3. Поиск и ответ

4. Проверка качества

80 минут · 3 демонстрации



girafe
ai

Ответ ошибочный. Где потеряли факт?

УЧЕБНЫЙ ПРИМЕР

В источнике

Обычный товар → 14 дней
Цифровой товар → 7 дней

Ответ модели

«Цифровой товар можно вернуть за 14 дней»

Текст?

Чанк?

Выдача?

Ответ?

Диагностика по промежуточным результатам

01

Документы и чанки

Текст, источник, границы фрагмента



girafe
ai

Два контура RAG

ПОДГОТОВКА БАЗЫ

Документы
текст + metadata

→

Чанки
границы + ID

→

Эмбеддер
векторы

→

Хранилище
индекс + текст

КАЖДЫЙ ЗАПРОС

Вопрос
полный запрос

→

Retriever
кандидаты

→

Контекст
отбор + ссылки

→

LLM
ответ

Document = текст + происхождение

page_content

«Для цифровых товаров срок возврата — 7 дней»

metadata

```
source: rules.pdf    page: 3
section: Возврат     chunk_id: rules-v2-03
```

Текст отвечает на вопрос. Metadata позволяет проверить ответ.

Практика 1 · что загрузили?

НОУТБУК · 4 МИН

CSV
одна строка

JSON
одна запись

Metadata
source + doc_id

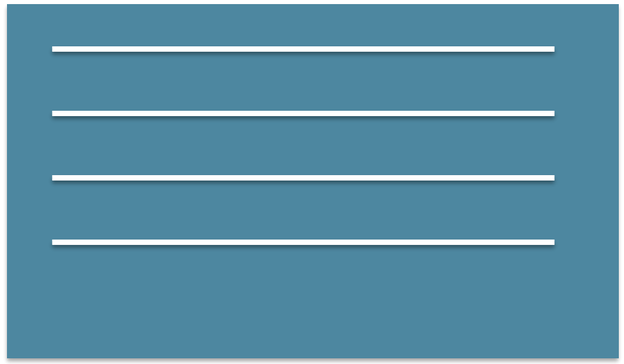
```
print(len(raw_docs))
print(raw_docs[0].page_content[:400], raw_docs[0].metadata)
```

Что здесь считается одним документом?

Чанк: точность ↔ достаточный контекст

Слишком крупно

Несколько тем в одном векторе



Слишком мелко

Правило без исключения



Целостный фрагмент

Правило + условие + источник

Правило + условие

Другой раздел

Размер выбирается по запросам и ограничениям моделей

Recursive splitter: от крупных границ к мелким

Абзацы `\n\n`

Строки `\n`

Слова `пробел`

Символы `последний шаг`

Разделители сохраняют структуру приблизительно

Размер и overlap — разные решения

L = 500 · O = 200 · шаг = 300



Объём ≈ L / (L − O)

× 1,67

для фиксированных окон

Символы ≠ токены. Overlap добавляет повторы.

Практика 2 · найдите потерянное условие

НОУТБУК · 4 МИН

Вариант A

size = 80

overlap = 0

Вариант B

size = 180

overlap = 30

Где правило? Где исключение?

Сохранился ли источник?

Фиксированные окна · символы · затем recursive_parts

02

Эмбеддинги и кэш

Роли входа, версия модели, повторные вычисления



girafe
ai

E5: разные роли входа

query:

Как вернуть цифровой товар?

passage:

Срок возврата — 7 дней.

Один E5-энкодер

Разные роли входа

Общее пространство

Два метода API не гарантируют разные векторы

Эмбеддер выбираем на своих вопросах

Язык

Русский корпус

Запросы

Термины и перефразировки

Длина

Обрезка входа

Ресурсы

Время и память

Leaderboard → кандидаты. Свои вопросы → выбор.

Кэш: повторный текст без повторного forward

```
key = hash(model_version, role, preprocessing, text)
```

Запрос к кэшу

Есть готовый вектор?

HIT → прочитать

Повторный проход

MISS → вычислить и сохранить

Холодный проход

Кэш эмбеддингов и поисковый индекс — разные компоненты

Векторное хранилище: не только вектор

ID	Текст	Вектор	Metadata
rules-01	Правило возврата	[0.12, ...]	page: 2
rules-02	Цифровые товары	[0.12, ...]	page: 3
rules-03	Срок обработки	[0.12, ...]	page: 4

Стабильные ID | **Версия корпуса** | **Версия эмбеддера**

Новая модель → проверить совместимость и переиндексировать

03

Поиск и ответ

Полный корпус, выдача, контекст



girafe
ai

Retriever — способ получить документы

query → list[Document]

BM25

По словам

Dense

По векторам

arXiv

Внешний поиск

Одинаковый интерфейс · разные механизмы

Для сравнения локальных retriever нужен один корпус

Пять документов вместо всей базы

```
docs = splitter.split_documents(raw_docs)
docs = db.similarity_search(query, k=5)
bm25 = BM25Retriever.from_documents(docs)
```

Сколько документов теперь видит BM25?

```
chunks = splitter.split_documents(raw_docs)
hits = db.similarity_search(query, k=5)
bm25 = BM25Retriever.from_documents(chunks)
```

raw_docs → chunks → hits · разные переменные

Top-k нужно превратить в контекст

[1] Правило

[2] Исключение

[1] Дубликат



Контекст

Без дублей

С метками источников

В пределах бюджета

Инструкции + история + документы + резерв ответа

Ссылка должна подтверждать конкретное утверждение

Диалог: восстановить полный вопрос

Предыдущий вопрос

«Что такое ImageBind?»

Новая реплика

«Какие модальности она объединяет?»

Самостоятельный запрос

«Какие модальности объединяет ImageBind?»

Rewrite восстанавливает вопрос; факты проверяем по источникам

Практика 3 · выдача раньше ответа

НОУТБУК · 6 МИН

1 · Найти

BM25 по всем chunks

2 · Проверить

Подходит ли текст?

3 · Ответить

Утверждение + источник

Возврат цифрового товара. А какой точный email?

Локальные данные · prompt · ответ студентов по источникам

04

Проверка качества

Релевантность, полнота, опора на источник

girafe ai

Мини-eval: одна причина за раз

Релевантны: A, C **Найдены: A, B, D**

Recall@3 = 1 / 2

Нашли половину релевантного

Precision@3 = 1 / 3

Один полезный из трёх

Retrieval отдельно

Правильность и подтверждённость ответа отдельно

Один параметр за эксперимент · одинаковые вопросы

Итоги занятия

1. Документы и чанки
2. Эмбеддинги и кэш
3. Поиск и ответ
4. Проверка качества

Вопросы?



girafe ai

Один интерфейс. Разные потери.

CSV	**Строка + названия колонок**	Потеря связей между строками
JSON	**Записи + выбранные поля**	Неверный путь к содержимому
HTML	**Основной текст страницы**	Меню и служебные блоки
PDF	**Текст + страница**	Колонки, формулы, сканы

Проверить page_content до индексации

Pooling: один вектор из токенов

Для	цифровых	товаров	[PAD]	[PAD]
1	1	1	0	0

attention_mask исключает padding

$$v = \Sigma\, m_i h_i \,/\, \Sigma\, m_i \qquad e = v \,/\, \|v\|_2$$

Токены → среднее → L2-нормировка

Нормированные векторы: dot product = cosine

Материалы и источники

Основа: 4_Retrieval_Augmented_Generation_Part2.ipynb

LangChain · Document loaders

LangChain · Recursive splitter

Multilingual E5 · model card

LangChain · Embeddings interface

LangChain · CacheBackedEmbeddings

LangChain · Chroma

LangChain · BM25Retriever

Схемы: авторские · оформление: предоставленный шаблон girafe ai