Архитектура LLM I

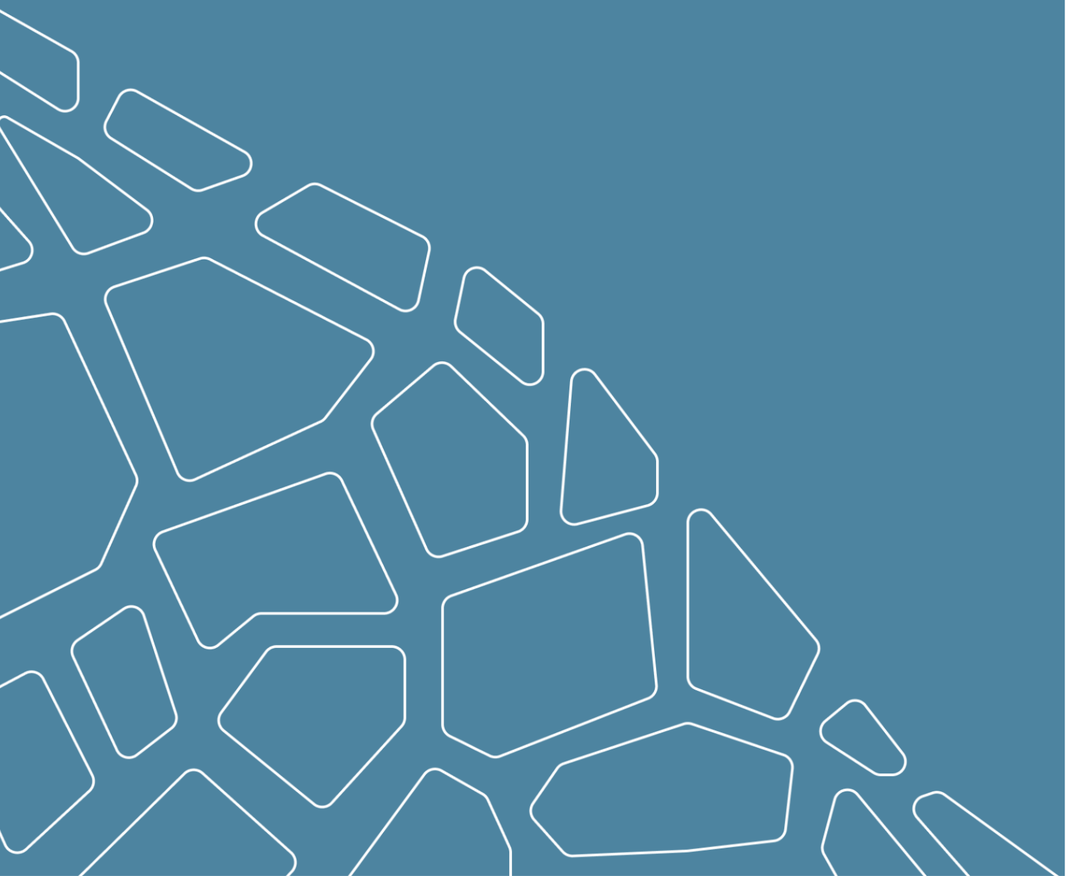
От текста до работающего decoder



МФТИ, осень 2026

План

Лекция 1:
Архитектура LLM



1. Текст, токены, embeddings
2. Attention и порядок
3. Позиционные представления
4. Encoder и decoder
5. Устройство блока
6. Языковая модель

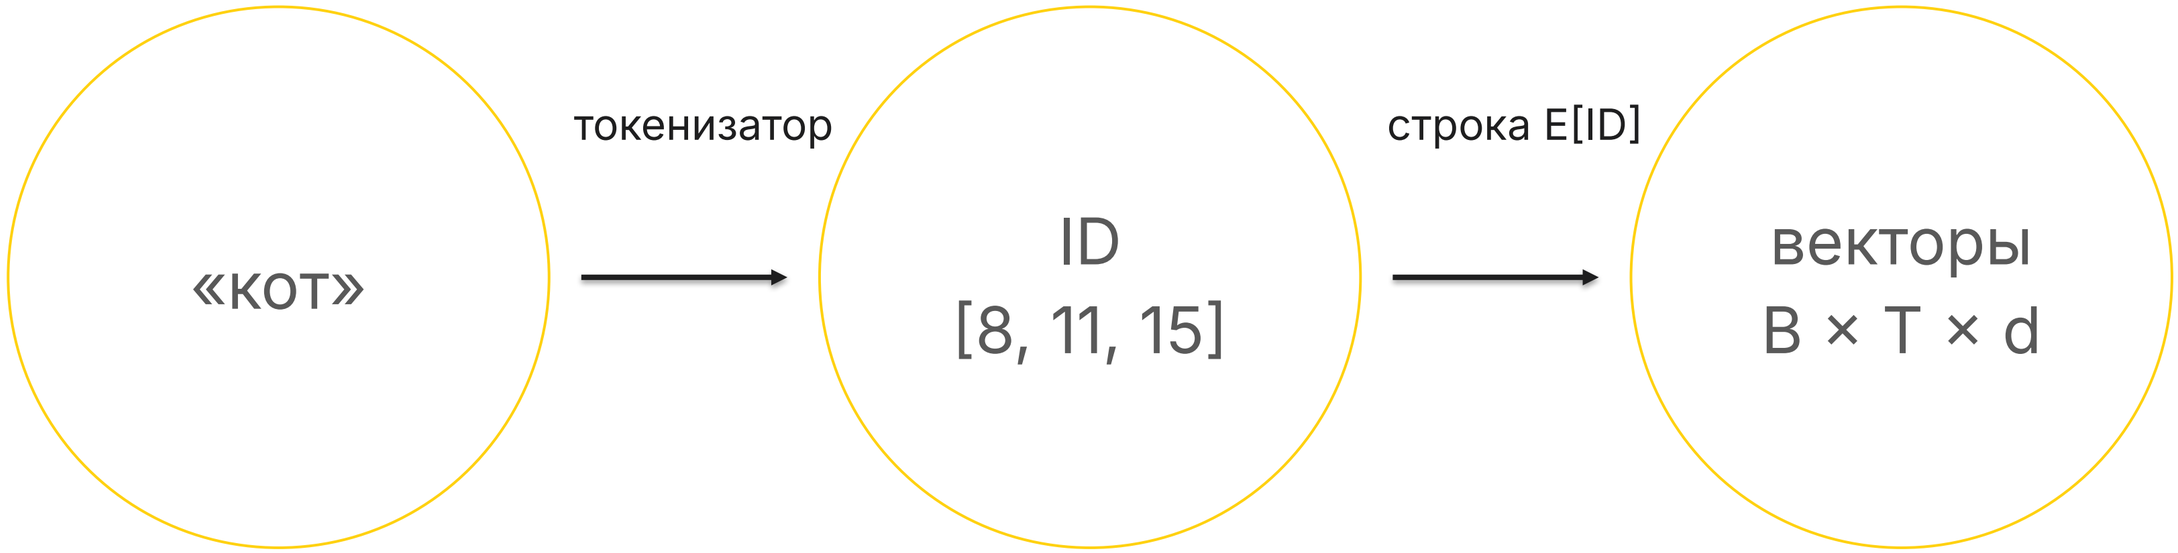
Текст → токены → embeddings

girafe ai

01

Текст → числа

BPE склеивает частые пары символов. Близкие ID ≠ близкий смысл.



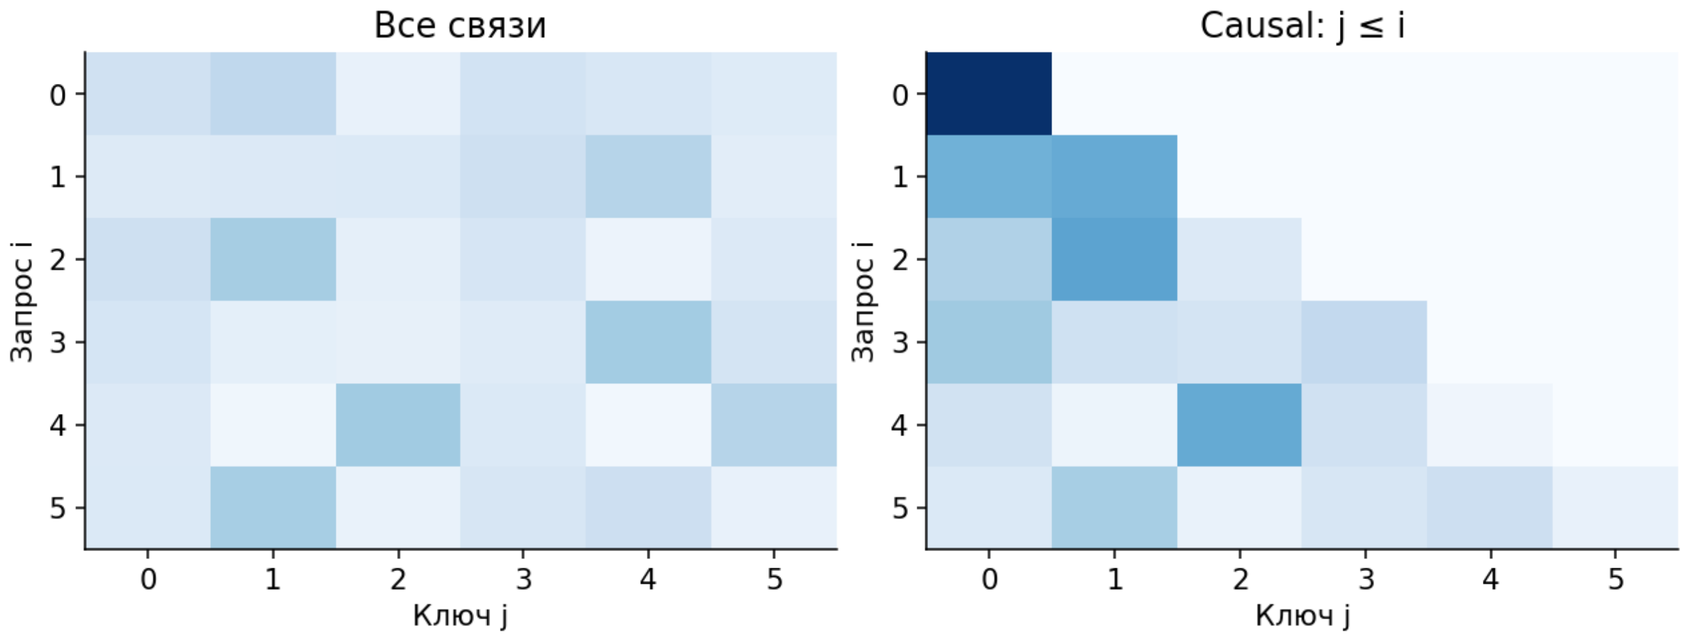
Attention и порядок



02

Self-attention

$$A = \mathrm{softmax}(Q \cdot K^{T} / \sqrt{d_h} + M), \quad Y = A \cdot V$$



Без позиций: переставили вход → переставился выход

Позиционные представления

girafe ai

03

Откуда модель знает порядок

Способ	Где	Как
Learned	вход X	обучаемая таблица
Sinusoidal	вход X	sin / cos разных частот
RoPE	Q и K в каждой голове	поворот на угол $t \cdot \omega$
NoPE	нигде	остаётся только causal mask

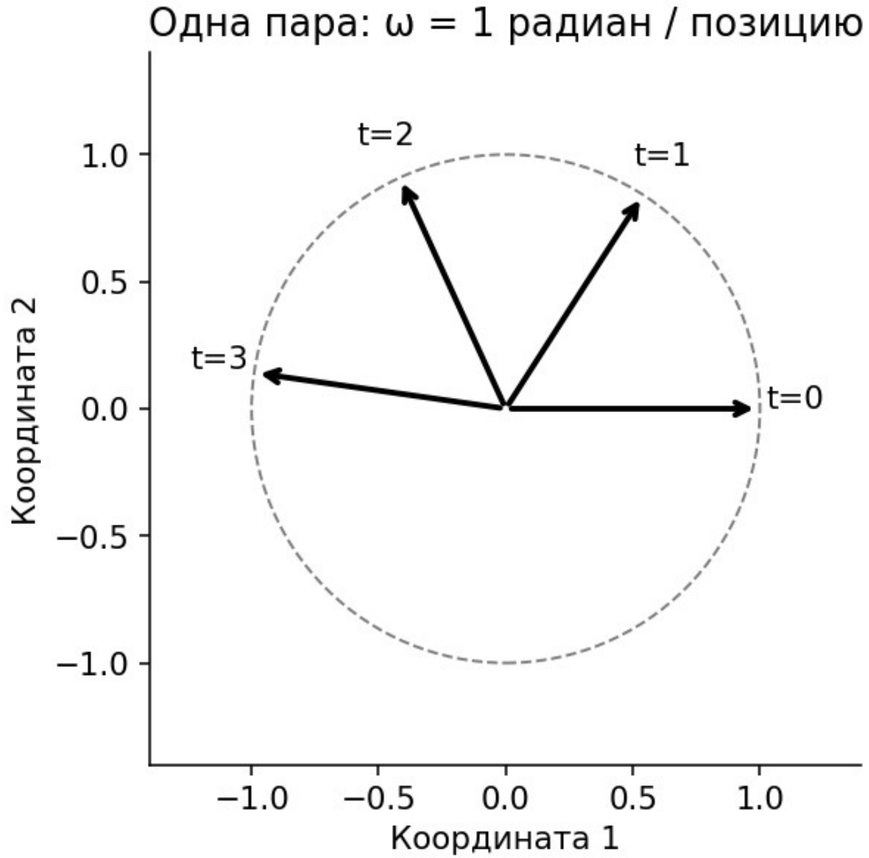
Запустилась на длине 128 ≠ хорошо работает на длине 128

RoPE: позиция = поворот

Поворачиваем пары координат Q и K на угол t·ω

Скалярное произведение зависит от s − t

Длина вектора не меняется, V не вращаем



Encoder и decoder

girafe ai

04

Кто смотрит в будущее

Модель	Видит	Учится
BERT	весь вход	восстановить [MASK]
GPT	себя и прошлое	предсказать следующий токен
Encoder–decoder	вход + свой префикс	переводить / генерировать

«Убрал causal mask — loss стал лучше!»
Модель: «Спасибо, ответы лежали в соседнем столбце»

Устройство блока

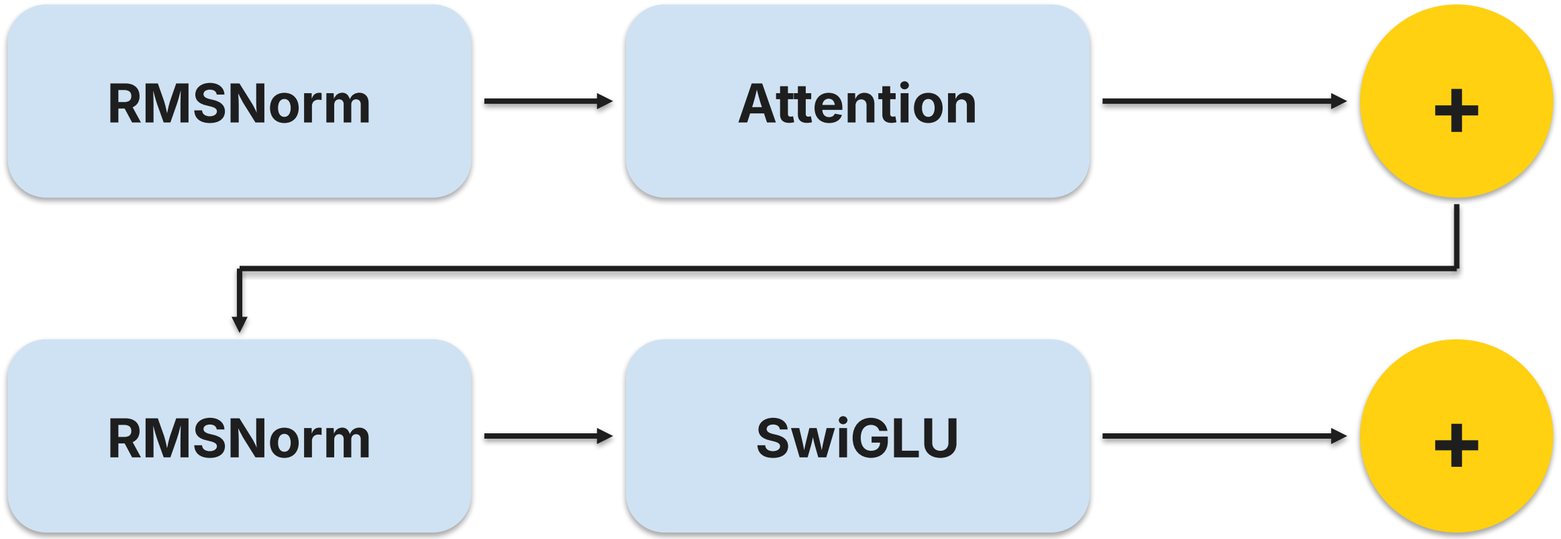
girafe ai

05

Transformer-блок (pre-norm)

смешивает токены

каждый токен отдельно



Residual: x + f(x) — прямой путь для градиента

SwiGLU = SiLU(x·W_g) ⊙ (x·W_u), затем W_d

Языковая модель

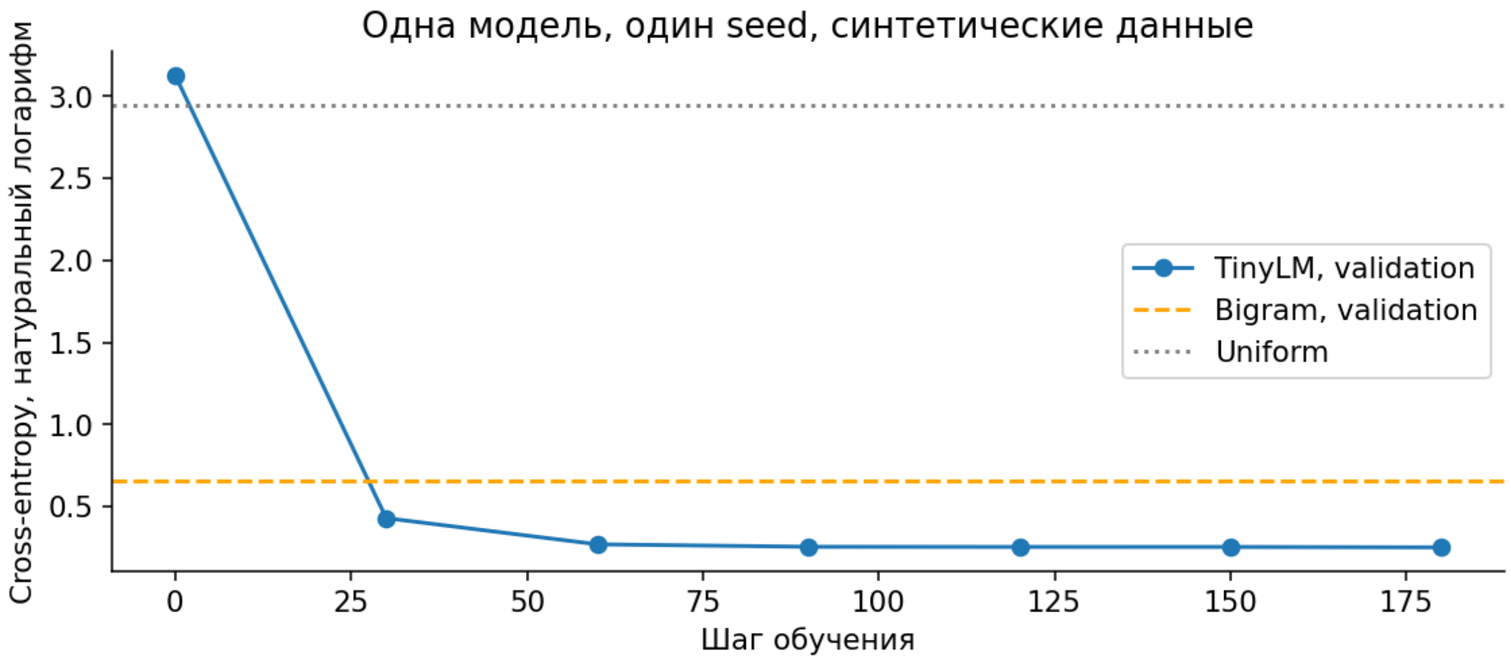


girafe
ai

06

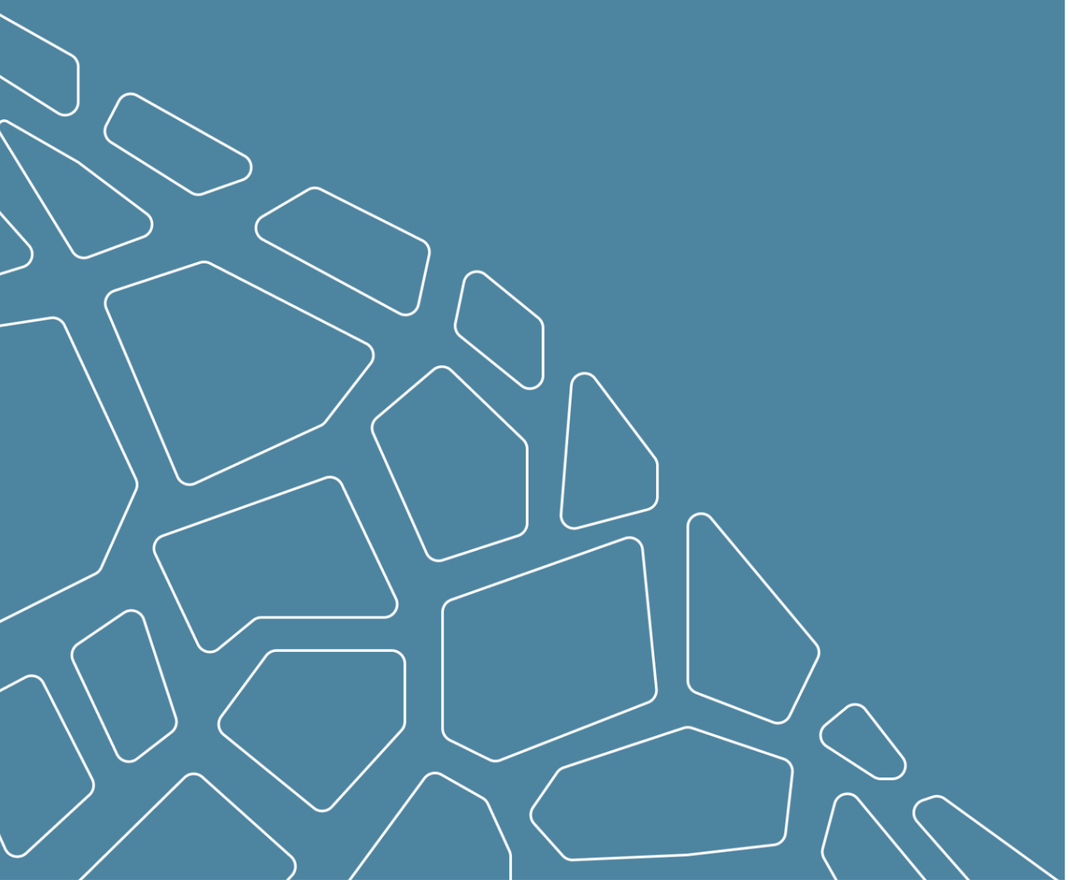
Обучение и генерация

logits → cross-entropy; цель — следующий символ



Генерация: выбрали токен → добавили на вход → повторили

Итоги



1. Токен → ID → обучаемый вектор
2. Attention сам по себе не знает порядок
3. Позиции: добавить вектор или повернуть Q/K
4. Causal mask: не подсматриваем в будущее
5. Блок = norm + attention + MLP + residual
6. LM: cross-entropy и генерация по токену

Спасибо за внимание!

Вопросы?

