Архитектура LLM II

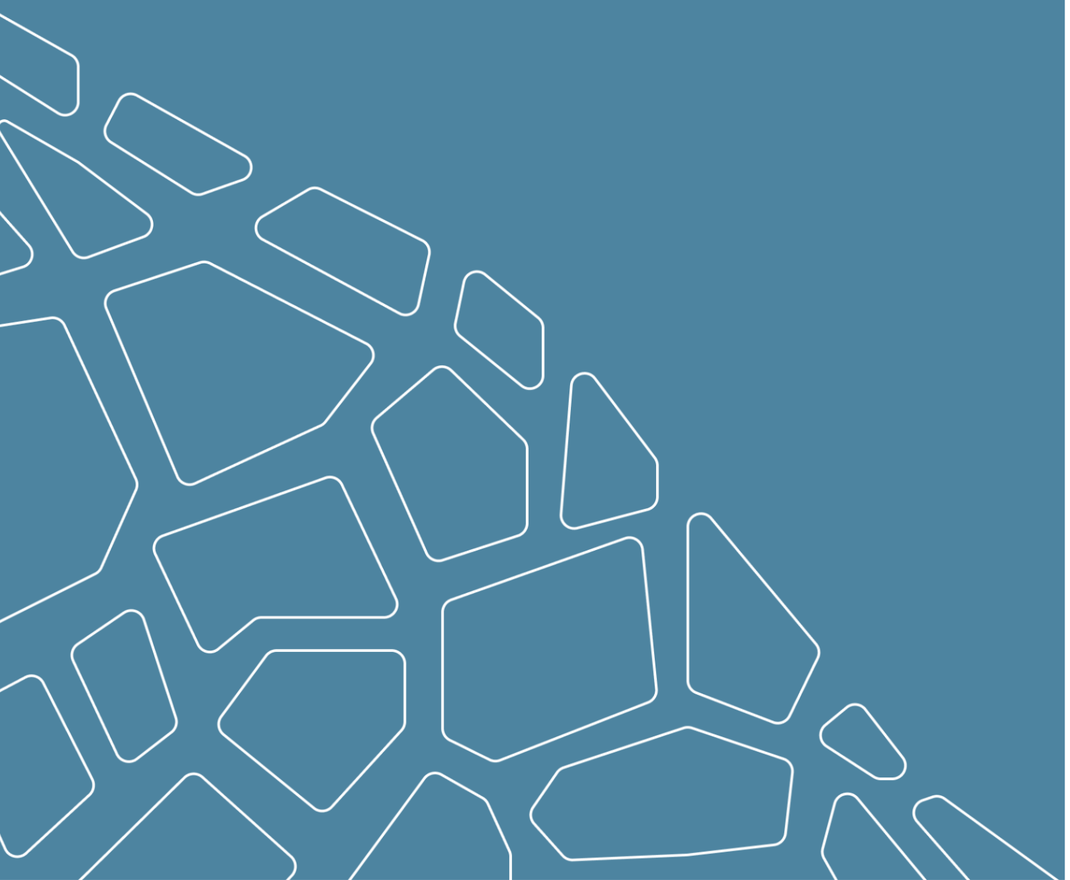
Почему attention дорогой



МФТИ, осень 2026

План

Лекция 2:
Почему attention дорогой



1. Стоимость attention
2. Генерация и KV-cache
3. MQA, GQA, MLA
4. Sliding window и sparse
5. Архитектура или реализация
6. Линейное внимание, SSM, Mamba
7. Разбор: DeepSeek-V3 и Qwen3.8

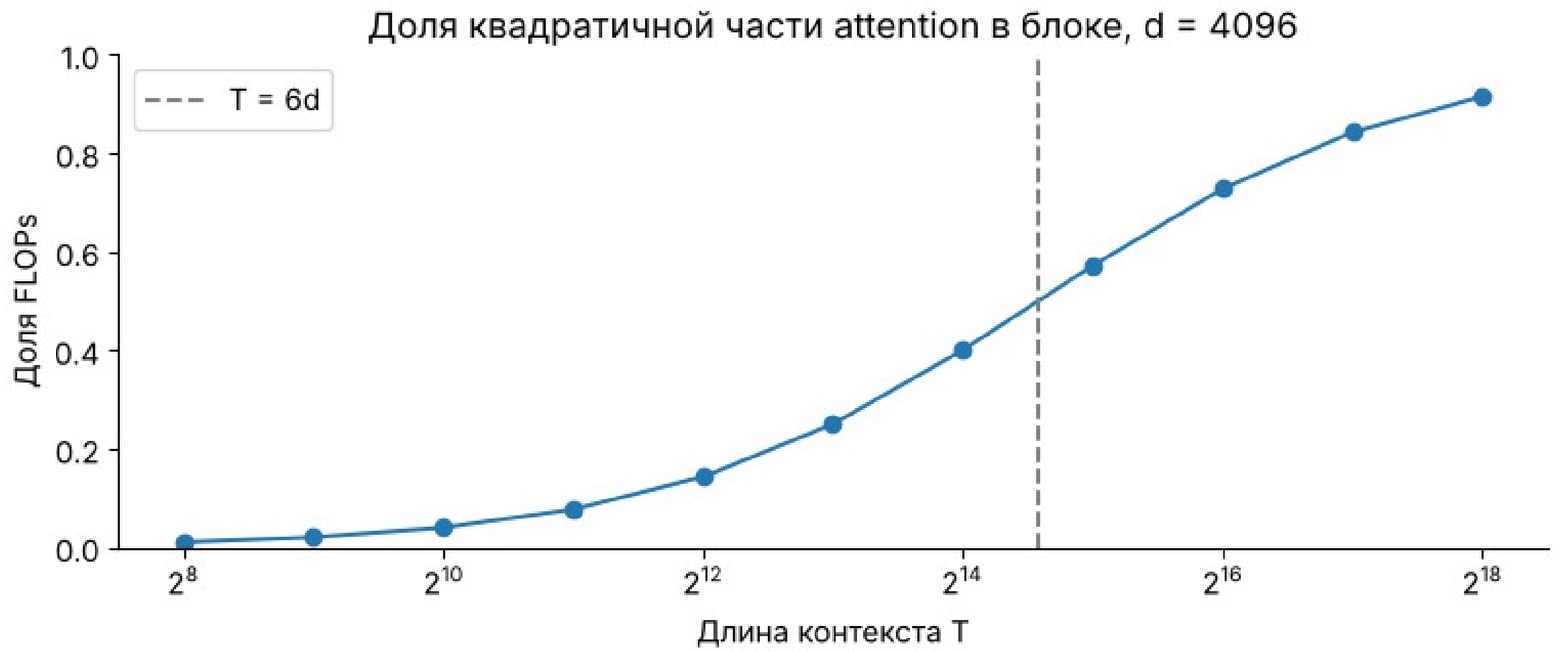
Стоимость attention

girafe ai

01

Attention растёт как T^2

Матрица scores при T = 128K: 1 TiB на слой



При T > 6d attention дороже всех матриц весов

Генерация и KV-cache



02

KV-cache: память вместо пересчёта

Prefill — весь промпт сразу. Decode — по одному токену, K и V прошлого из кэша

Llama-3-8B-подобная модель, bf16:

128 KiB	**16 GiB**	**≈ веса**
на один токен	на контекст 128K	одна длинная сессия

Decode упирается в чтение памяти, а не в FLOPs

MQA, GQA и MLA

girafe ai

03

Как уменьшить кэш

Способ	Что хранится на слой	На токен *
MHA	K, V всех 32 голов	512 KiB
GQA-8	K, V 8 групп голов	128 KiB
MQA	K, V одной головы	16 KiB
MLA	латент 512 + RoPE-ключ 64	DeepSeek-V3: 69 KiB

* N = 32, d_h = 128, bf16. MLA в DeepSeek-V3: в 71 раз меньше, чем MHA

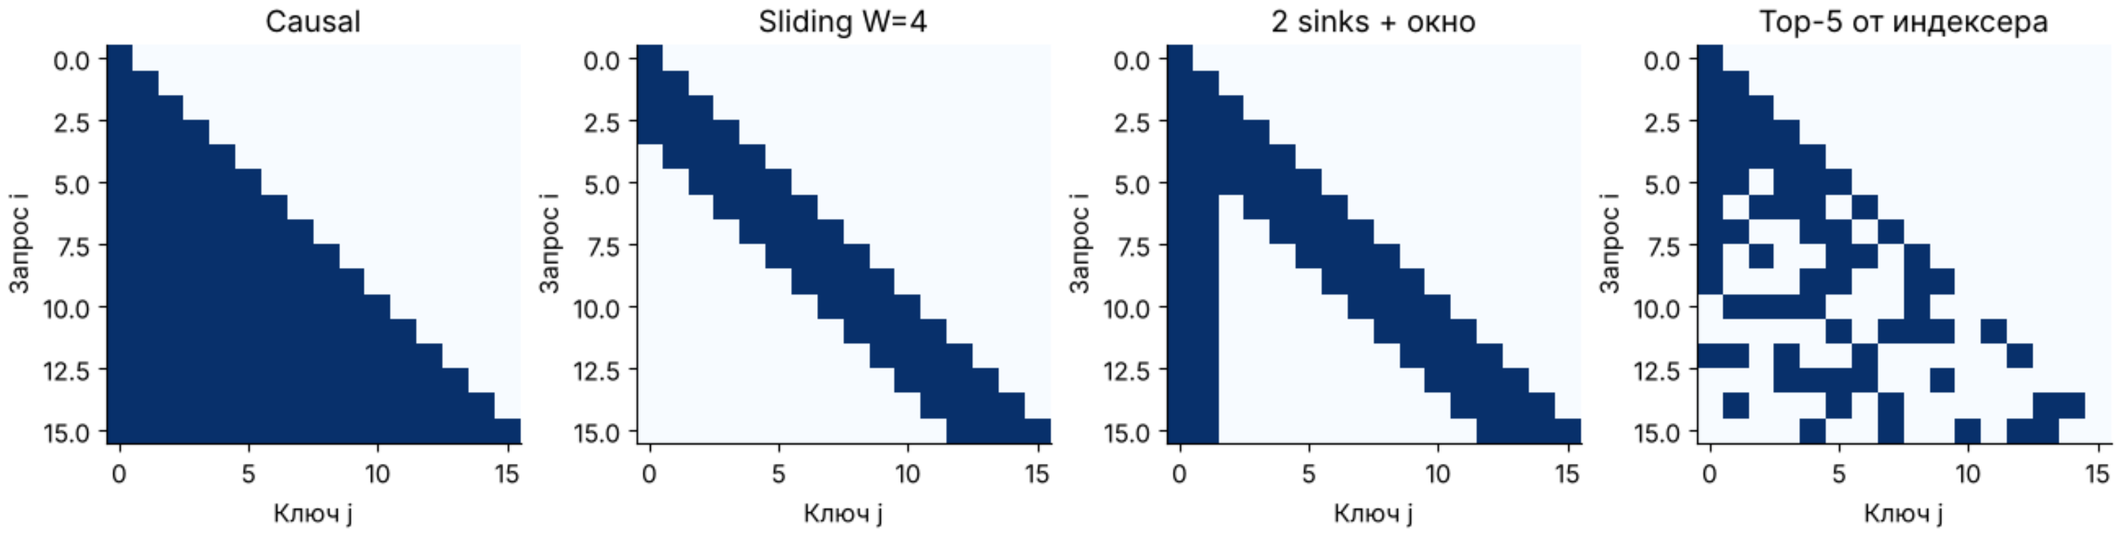
Sliding window и sparse attention

girafe ai

04

Смотрим не на все токены

Окно: Mistral, Gemma. Top-k с индексером: DeepSeek-V3.2, Qwen3.8



Окно экономит кэш, top-k — вычисления

Архитектура или реализация

girafe ai

05

Архитектура или реализация

Тип	Меняет f(x)?	Примеры
Архитектура	да, нужно обучать	GQA, MLA, окно, sparse, SSM
Реализация	нет	FlashAttention, PagedAttention
Серая зона	чуть-чуть	fp8 KV-cache, int4 веса

FlashAttention: те же FLOPs, но матрица T×T никогда не лежит в памяти целиком

Линейное внимание, SSM и Mamba



girafe ai

06

Состояние фиксированного размера

Линейное внимание: $S_t = S_{t-1} + k_t v_t^T, \quad o_t = S_t^T q_t$

Gated DeltaNet: $S_t = \alpha_t(I - \beta_t k_t k_t^T)S_{t-1} + \beta_t k_t v_t^T$

Mamba-2 ≈ линейное внимание с затуханием

Помнят последнее значение переменной (эксперимент из ноутбука):

0.17

линейное

0.84

delta rule

Разбор: DeepSeek-V3 и Qwen3.8-Flash-Next



girafe ai

07

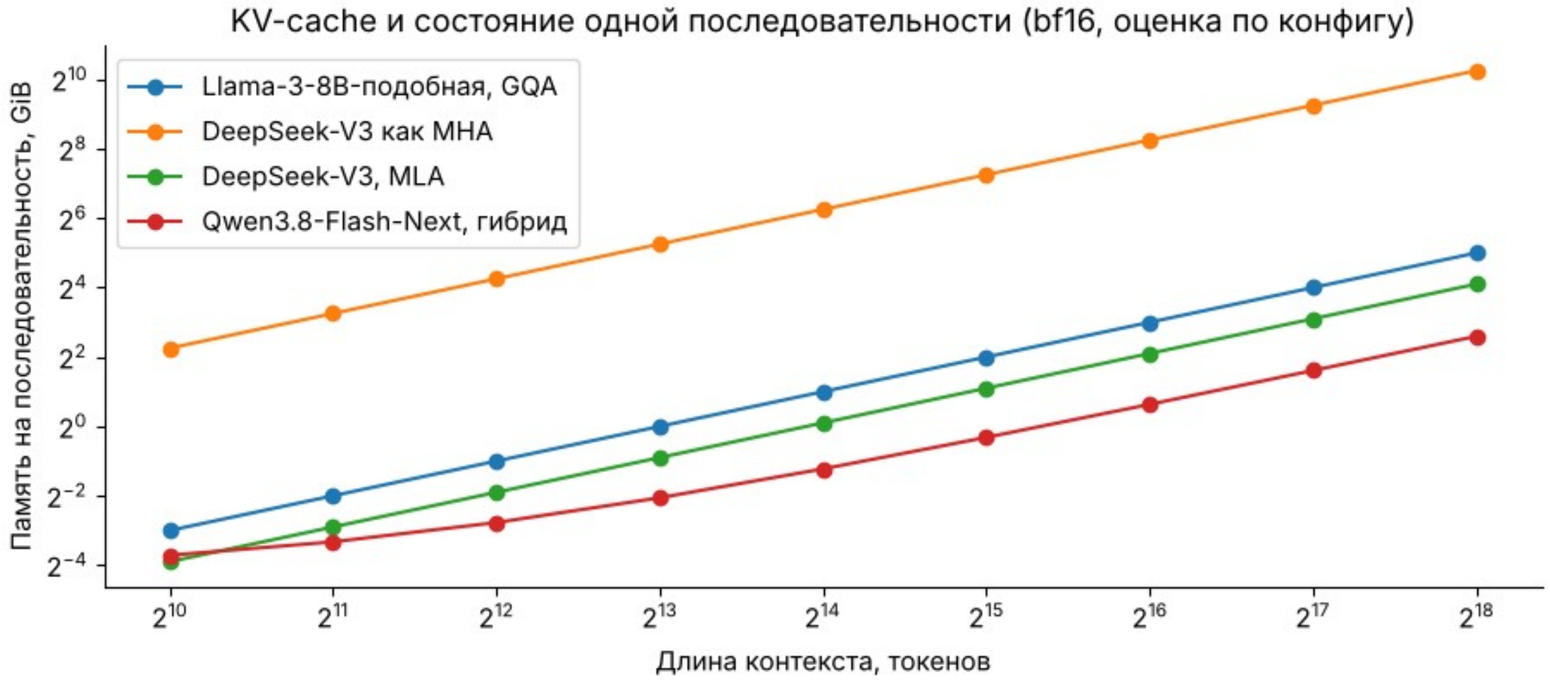
Две реальные модели

	DeepSeek-V3	Qwen3.8-Flash-Next
Параметры	671B, 37B активны	125B, 6B активны
Attention	MLA во всех 61 слоях	3 × Gated DeltaNet + 1 × sparse GQA
Кэш на токен	69 KiB	24 KiB + 54 MiB состояние
Контекст	128K	262K

Обе используют MoE — это тема следующего занятия

Память одной последовательности

Оценка по конфигам, bf16



128K: GQA 16 GiB · MLA 8.6 GiB · гибрид 3.1 GiB

Итоги

1. Attention ~ T^2, на длинном контексте он главный
2. KV-cache: decode ограничен памятью
3. GQA и MLA уменьшают кэш
4. Окно и top-k: смотрим не на всё
5. FlashAttention не меняет модель, GQA меняет
6. SSM / DeltaNet: фиксированное состояние
7. Гибриды: линейные слои + немного attention

Спасибо за внимание!

Вопросы?

